

Elektrotehnički fakultet

Univerzitet u Sarajevu

Odsjek za računarstvo i informatiku



VJEŠTAČKA INTELIGENCIJA

## **PROJEKAT**

### **DRUNKEN DRIVER DETECTION**

Džana Krnjić, 19295

Irma Galijašević, 19459

Ayša Nil, 19372

# 1. Izbor teme i opis problema

Vožnja pod uticajem alkohola ili drugih psihoaktivnih supstanci predstavlja jedan od glavnih uzroka saobraćajnih nesreća širom svijeta. Uprkos zakonima, kontrolama i kampanjama osvješćivanja, vozači pod uticajem i dalje predstavljaju ozbiljnu prijetnju bezbjednosti u saobraćaju. Alkohol negativno utiče na vozačke sposobnosti smanjujući motoričke vještine, koncentraciju, usporavajući reakcije, narušavajući vid i donošenje odluka. Osim fizičkih efekata, alkohol može negativno uticati na emocionalno stanje vozača, povećavajući agresivnost i smanjujući samokontrolu, što dodatno ugrožava sigurnost saobraćaja. Prepoznavanje takvih vozača u realnom vremenu može spasiti brojne živote i smanjiti broj nesreća.

Rješenje ovog problema ima značajnu praktičnu vrijednost i može se integrisati u pametne sigurnosne sisteme u automobilima, kao i u nadzorne sisteme za praćenje saobraćaja. Također, može doprinijeti razvoju autonomnih sistema koji u budućnosti mogu spriječiti vožnju pod uticajem, ili automatski alarmirati nadležne službe.

Cilj ovog projektnog zadatka je razvoj sistema za detekciju vozača pod uticajem alkohola koristeći metode vještačke inteligencije. Korištenjem dostupnih dataset-ova, planirano je treniranje modela koji će na osnovu vizuelnih (slike ili video zapisi), biometrijskih (npr. oči, lice, pokreti glave) ili senzorskih podataka (npr. ubrzanje, pritisak na papučicu, GPS podaci) klasifikovati stanje vozača kao *triježno* ili *pod uticajem (sober or drunk)*.

## 1.1 Definisanje osnovnih pojmova

### 1. Dataset (skup podataka)

Dataset je strukturirani skup podataka koji se koristi za treniranje i evaluaciju modela. Kvalitetan dataset sa odgovarajućim anotacijama ključan je za tačnost modela.

### 2. Classification (klasifikacija)

Klasifikacija je proces učenja modela koji odlučuje kojoj kategoriji pripada ulazni podatak. U ovom slučaju, model klasifikuje da li je vozač trijezan ili pijan na osnovu skupa karakteristika.

### 3. Computer Vision (računarski vid)

Računarski vid je područje vještačke inteligencije koje omogućava računarima da "vide",

analiziraju i interpretiraju slike i video sadržaj na način sličan ljudima. U kontekstu ovog projekta, koristi se za detekciju znakova omamljenosti na licu, očima, položaju glave i drugim fizičkim indikatorima.

#### 4. Deep Learning (duboko učenje)

Duboko učenje je podskup mašinskog učenja koji koristi neuronske mreže sa više slojeva za automatsko učenje karakteristika iz podataka, posebno korisno u radu sa slikama, videima i zvukom.

#### 5. CNN (konvolucione neuronske mreže)

CNN su specijalizovane neuronske mreže koje se koriste za obradu slika i prepoznavanje obrazaca, kao što su pokreti očiju, zatvaranje kapaka ili položaj glave, što su često indikatori pospanosti ili alkoholne omamljenosti.

#### 6. Biometrijski pokazatelji

Biometrijski pokazatelji obuhvataju fiziološke i ponašajne karakteristike osobe, kao što su frekvencija treptanja, dilatacija zjenica, temperatura kože, broj otkucaja srca i slično. U sistemima za detekciju omamljenosti, oni mogu služiti kao indirektni pokazatelji konzumacije alkohola.

## 1.2 Pregled postojećih dataset-ova

U oblasti prepoznavanja stanja pijanstva pomoću računarskog vida i mašinskog učenja, dostupnost kvalitetnih i anotiranih skupova podataka (datasetova) je ograničena, što predstavlja značajan izazov za istraživače. Većina postojećih datasetova fokusira se na direktne ili indirektne biometrijske pokazatelje, uključujući promjene na licu, očima, položaju tijela ili termalnim karakteristikama.

U nastavku su predstavljeni neki od dostupnih i najčešće korištenih datasetova u ovoj oblasti:

##### a) Drunk vs Sober Infrared Image Dataset (Kipshidze et al.)

- **Izvor:** Kaggle / IEEE
- **Opis:** Termalne (infracrvene) slike lica pojedinaca u različitim fazama nakon konzumacije alkohola – odmah nakon, 20 minuta, 40 minuta i 60 minuta, kao i slike u trijeznom stanju.
- **Svrha:** Klasifikacija osoba kao *sober* ili *drunk* na osnovu promjena u termalnim obrascima lica.
- **Tip podataka:** .tif ili .jpg slike, visoke rezolucije, snimljene u kontrolisanom okruženju.
- **Prednosti:** Jasan vremenski razmak, dobar broj uzoraka, prikladno za binarnu i višeklasnu klasifikaciju.

- **Nedostaci:** Ograničen broj osoba (manji skup identiteta), što može uzrokovati prenaučenosť modela i smanjenu generalizaciju.

b) UTKFace Dataset

- **Izvor:** <https://susanqq.github.io/UTKFace/>
- **Opis:** Iako nije specifično napravljen za klasifikaciju pijanstva, ovaj dataset sadrži veliki broj slika lica s oznakama za dob, spol i etničku pripadnost. Koristi se kao pomoćni dataset za trening ili augmentaciju modela.
- **Svrha:** Može se koristiti za treniranje modela da prepozna normalna (triježna) stanja, kao kontrolni uzorak.

c) UCH-TTF (University of Chile Thermal Face)

- **Izvor:** Universidad de Chile
- **Opis:** UCH-TTF je termalni (infracrveni) dataset koji sadrži slike ljudskih lica snimljene termalnim kamerama u različitim uslovima.
- **Svrha:** Koristi se u istraživanjima za prepoznavanje lica, detekciju emocionalnih stanja i fizioloških promjena, uključujući i potencijalnu primjenu u detekciji pijanstva.
- **Karakteristike:**
  - Termalne slike visoke rezolucije.
  - Više uzoraka po osobi.
  - Kontrolisani uslovi snimanja.
- **Primjena u ovoj oblasti:** Iako sam dataset ne sadrži anotacije vezane za konzumaciju alkohola, zbog osjetljivosti termalne kamere na promjene u protoku krvi i temperaturi kože, može se koristiti kao pomoćni dataset ili kao osnov za istraživanja koja se bave detekcijom promjena izazvanih alkoholom.

d) PUCV-DTF (PUCV Drunk Thermal Face Dataset)

- **Izvor:** Pontificia Universidad Católica de Valparaíso (Čile)
- **Opis:** PUCV-DTF je jedan od rijetkih javno dostupnih datasetova koji eksplicitno sadrže termalne slike lica osoba prije i nakon konzumacije alkohola.

- **Svrha:** Detekcija stanja pijanstva korištenjem infracrvene termografije.
- **Karakteristike:**
  - Slike osoba u dvije klasifikacione kategorije: *sober* i *drunk*.
  - Fotografije su prikupljene u više vremenskih tačaka nakon konzumacije alkohola, slično kao i kod "Drunk vs Sober" dataset-a.
  - Anonimizirani podaci, etički odobren eksperiment.
- **Prednosti:**
  - Prava primjena u problemu klasifikacije pijanstva.
  - Bolja raznovrsnost u poređenju s nekim manjim datasetovima.
- **Nedostaci:**
  - Relativno mali broj ispitanika.
  - Potencijalna pristrasnost zbog homogenosti populacije.

## 2. Pregled stanja u oblasti

### 2.1 Analiza trenutnog stanja

Vožnja pod uticajem alkohola ili drugih psihoaktivnih supstanci predstavlja ozbiljan problem u saobraćaju širom svijeta. Statistike pokazuju zabrinjavajuće brojke, koje ukazuju na visoki rizik koji takvi vozači predstavljaju za sve učesnike u saobraćaju. Prema podacima prikupljenim od strane Nacionalne administracije za bezbjednost saobraćaja na autoputevima (NHTSA), u Sjedinjenim Američkim Državama, trećina svih saobraćajnih nesreća uključuje vozače pod uticajem alkohola. Također, statistika objavljena u članku na Forbesu ukazuje na povećanje broja nesreća tokom vikenda i prazničnih dana, te na veći broj nesreća koje uključuju muške vozače u odnosu na žene.

[Izvor: Forbes – Drunk Driving Statistics](#)

Izveštaj Svjetske zdravstvene organizacije (WHO) iz 2015. godine pokazuje značajne razlike među zemljama. Na primjer, u Južnoj Africi čak 58% svih nesreća povezano je s vožnjom pod uticajem alkohola, dok Kanada ima 34%, a Sjedinjene Američke Države nešto manji, ali i dalje zabrinjavajući procenat. Ovi podaci ukazuju na to da ni visoko razvijene zemlje nisu imune na ovaj problem, a na njega utiču brojni faktori, uključujući kvalitet infrastrukture, provođenje zakona i društvene norme.

Izveštaj Međunarodnog transportnog foruma (OECD/ITF, 2017) ističe da se broj nesreća izazvanih alkoholom u mnogim zemljama često potcjenjuje u službenim statistikama, te da bi stvarne brojke mogle biti i dvostruko veće. Ovaj izveštaj preporučuje sistematsko testiranje svih učesnika u ozbiljnim nesrećama i bolju harmonizaciju prikupljanja podataka između zemalja, kako bi se omogućila kvalitetna analiza i kreiranje efikasnih strategija prevencije.

[Izvor: OECD/ITF Report](#)

Današnji automobili postaju sve sofisticiraniji, zahvaljujući integraciji Internet of Things (IoT) tehnologije koja omogućava povezivanje vozila sa različitim uređajima i sistemima. Ovi automobili često dolaze sa ugrađenim kamerama, radarima, senzorima za detekciju pokreta, senzorima za pritisak na papučicu, GPS sistemima i mnogim drugim tehnologijama koje prate ponašanje vozača i uslove na cesti. Ovi uređaji prikupljaju podatke u realnom vremenu, što omogućava automatsko prepoznavanje sumnjivih ponašanja, poput smanjenog vremena reakcije, neodgovarajuće držanje volana ili poremećaje u kretanju vozila. Korištenjem računarskog vida, dubokog učenja i analize podataka sa ovih senzora, moguće je razviti sisteme koji mogu detektovati vozače pod uticajem alkohola ili drugih psihoaktivnih supstanci. Ovi sistemi mogu odmah upozoriti vozača ili čak automatski preduzeti akciju, kao što je aktiviranje sistema za kočenje ili obavješćavanje nadležnih službi, čime se značajno povećava sigurnost na putevima i smanjuje broj nesreća uzrokovanih vožnjom pod uticajem.

Trenutno postoje razna istraživanja koja se bave načinima implementacije takvih sistema. Primjer jednog istraživačkog rada uključuje i kliničku studiju osoba s različitim nivoima alkohola u krvi. U svom radu, autori su razvili sistem za predviđanje kritičnih nivoa alkohola u krvi (BAC) koristeći kamere za praćenje vozača, obavezne u mnogim zemljama. Sistem je evaluiran kroz simulaciono istraživanje sa 30 učesnika, pri čemu je pouzdano detektovao bilo kakav uticaj alkohola tokom vožnje sa područjem ispod krive karakteristike operativne tačnosti (AUROC) od 88%. Takođe, sistem je identifikovao vozače sa BAC iznad preporučene granice Svjetske zdravstvene organizacije od 0,05 g/dL sa AUROC sa 79% tačnosti. Ova istraživanja ukazuju na potencijal kamera za praćenje vozača u prevenciji vožnje pod uticajem alkohola.

[Leveraging driver vehicle and environment interaction](#)

Sljedeći članak pruža detaljan pregled trenutnih praksi i budućih smjerova u primjeni vještačke inteligencije (AI) za unapređenje sigurnosti u saobraćaju. Autori analiziraju različite AI modele i

senzore koji se koriste u analizama pogleda vozača, praćenju stanja vozača i analizi sigurnosnih kritičnih događaja (SCE). Također, istražuju komercijalno dostupne sisteme za praćenje vozača i analizu SCE-a, identifikujući ključne AI alate u industriji. Na kraju, članak pruža preporuke za buduća istraživanja, fokusirajući se na integraciju različitih senzora i AI modela za poboljšanje tačnosti i efikasnosti sistema za praćenje vozača i analizu SCE-a.

[Comprehensive Assessment of Artificial Intelligence Tools for Driver Monitoring and Analyzing Safety Critical Events in Vehicles](#)

Sličan sistem koji vrši evaluaciju vozača u prvih nekoliko minuta vožnje je već implementiran u Mercedes-Benz automobilu, s tim da je njihov ATTENTION ASSIST više namijenjen da detektira pospanost i umor, ali ima definisan protokol kako će se vozilo ponašati ako utvrdi da je vozač onemogućen da bezbjedno kontroliše vozilo. Više o ovom sistemu možete pročitati na sljedećem linku: [Izvor: Mercedes Benz](#)

## 2.2 Opseg problema i korištene metode vještačke inteligencije

Prema izvještaju Međunarodnog transportnog foruma (ITF), alkohol je značajan faktor u saobraćajnim nesrećama širom svijeta, sa velikim varijacijama u statistici među zemljama. Zbog toga su razvijeni različiti sistemi za detekciju vozača pod uticajem alkohola kako bi se smanjio broj nesreća.

### 2.2.1 Opseg problema

1. Vizuelna analiza pomoću kamera  
Sistemi koriste kamere za praćenje lica vozača kako bi detektovali znakove intoksikacije, kao što su promjene u izrazu lica, pokretima glave i očiju. Na primjer, istraživači su razvili AI algoritme koji analiziraju snimke lica vozača kako bi procijenili nivo intoksikacije sa tačnošću od 75%.  
(<https://www.livescience.com/technology/artificial-intelligence/new-in-car-ai-can-spot-drunk-drivers-by-constantly-scanning-their-face>)
2. Analiza biometrijskih signala  
Korišćenjem senzora za elektrokardiogram (ECG), fotopletizmografiju (PPG) i elektrodermalnu aktivnost (EDA), moguće je detektovati fiziološke promjene povezane sa konzumacijom alkohola. Ove metode omogućavaju klasifikaciju nivoa intoksikacije bez potrebe za invazivnim testovima.  
(<https://www.mdpi.com/1424-8220/25/5/1281>)
3. Sistemi za praćenje pažnje vozača

Automobilski sistemi poput Mercedes-Benz Attention Assist analiziraju obrasce vožnje, uključujući upravljanje i ponašanje vozača, kako bi identifikovali znakove umora ili smanjene pažnje, što može uključivati i uticaj alkohola.

4. Detekcija pomoću AI kamera na putevima

U nekim regijama, poput Devon i Cornwall u Velikoj Britaniji, testiraju se AI kamere koje analiziraju slike prolaznih vozila kako bi identifikovale znakove intoksikacije kod vozača i obavijestile policiju za dalju akciju.

(<https://www.thesun.co.uk/motors/32362391/new-ai-cameras-driver-drunk-drugs-uk>)

5. Integracija AI sistema u vozila

Projekti poput Driver Alcohol Detection System for Safety (DADSS) razvijaju tehnologije koje omogućavaju vozilima da pasivno detektuju prisustvo alkohola kod vozača putem senzora za dah ili dodir, bez potrebe za aktivnim učešćem vozača.

(<https://dadss.org>)

## 2.2.2 Metode vještačke inteligencije

Metode koje su korištene u prethodno opisanom opsegu problema su sljedeće:

- Machine learning: korišten za klasifikaciju ponašanja vozača kao “normalno” ili “pod uticajem alkohola”
- Computer vision: Detekcija vizuelnih znakova pospanosti, dezorijentacije, zatvaranja očiju, promjena izraza lica, gledanje van puta.
- Deep learning: Primjena složenih neuronskih mreža za obradu slike, sekvenci ponašanja i biometrijskih signala
- Sensor Fusion i Embedded AI: integracija više senzora u vozilu (npr disanje, kontakt sa volanom, kamera) sa AI modelima za detekciju stanja vozača

## 2.3 Osvrt na postignute rezultate

1. Efikasnost postojećih sistema

- Vizuelna analiza pomoću kamera je obećavajuća, ali ima ograničenja u varijabilnosti uslova, kao što su osvjtljenje ili promjene u ponašanju vozača. Iako neki sistemi pokazuju visoku preciznost (do 75% u detekciji intoksikacije), često zavise od specifičnih uslova (npr. jasnoća slike, ugao snimanja, itd.). U idealnim uslovima, ovi sistemi mogu biti vrlo efikasni, ali im može biti teško da detektuju alkoholizovane vozače u realnim, promenljivim saobraćajnim uslovima.



- Biometrijska detekcija, kao što je analiza ECG ili PPG signala, može biti vrlo precizna u detekciji fizioloških promjena koje nastaju nakon konzumiranja alkohola, međutim, ovi sistemi se još uvek nalaze u fazi istraživanja i razvoja, te nisu široko implementirani u praksi.
- Sistemi za praćenje pažnje vozača (poput Mercedes-Benz Attention Assist) pokazuju dobar napredak u detekciji smanjenja pažnje, što može biti indirektan znak alkoholisanja. Međutim, ovi sistemi se više fokusiraju na umor i distrakciju, a ne direktno na alkohol.
- AI kamere na putevima i automatske detekcije putem senzornih sistema u vozilima pokazuju značajan potencijal za prepoznavanje alkoholisanja bez učešća vozača, ali izazov predstavlja implementacija i globalna primjena ovih sistema, jer zahtijeva široku adaptaciju infrastrukture i zakonodavnu podršku.

## 2. Ograničenja postojećih sistema

- Preciznost i tačnost: Neki od sistema još uvijek nisu dovoljno precizni u detekciji niskog nivoa alkoholizacije. Na primjer, vizuelna detekcija može propustiti suptilne znakove alkoholisanja, dok biometrijska detekcija može imati greške zbog varijacija u fiziološkim karakteristikama vozača.
- Prilagodljivost i skalabilnost: Implementacija ovih sistema u stvarnom svijetu je izazovna. Sistemi kao što su kamere na putevima ili biometrijski senzori mogu biti skupi i teško je osigurati njihovu univerzalnu primjenu. Takođe, različiti uslovi (npr. vremenski uslovi, različiti tipovi vozila) mogu uticati na tačnost.
- Regulacija i privatnost: Implementacija AI sistema u vozilima ili u saobraćaju postavlja pitanje privatnosti i etičkih dilema. Zakonodavni okvir za korišćenje takvih tehnologija još uvek nije globalno usklađen, što može usporiti razvoj i primjenu ovih sistema.

Postignuti rezultati u detekciji vozača pod uticajem alkohola pokazuju veliki napredak, ali i dalje postoje značajni izazovi. Iako su metode kao što su vizuelna analiza, biometrijska detekcija i sistemi za praćenje pažnje vozača pokazali potencijal, efikasnost ovih sistema u stvarnim uslovima se još uvijek testira. S obzirom na visoke troškove implementacije, kao i izazove u preciznosti i skalabilnosti, potrebno je dalje istraživanje kako bi se poboljšala tačnost detekcije i smanjila cijena implementacije.

Za budućnost, očekuje se da će se kombinacija različitih tehnologija, kao što su AI kamere, biometrijski senzori i AI analize ponašanja vozača, koristiti zajedno kako bi se stvorili precizniji i efikasniji sistemi za prevenciju vožnje pod uticajem alkohola. Zakonodavni okvir i društvena prihvaćenost ovih tehnologija također će igrati ključnu ulogu u njihovom širenju.

## 3. Izbor, analiza i pretprocesiranje dataset-a

### 3.1 Izvor skupa podataka

Dataset je preuzet sa [Kaggle platforme](#), pod nazivom: "Drunk vs Sober Infrared Image Dataset" Autor: Lasha Kipshidze

Dataset je javan i besplatan za preuzimanje preko Kaggle API-ja ([kagglehub](#)).

### 3.2 Pregled dataset-a

#### 1. Format i način preuzimanja

**Format:** Dataset je organizovan u direktorijume koji sadrže `.jpg` slike u infracrvenom (termalnom) spektru.

**Preuzimanje:** Urađeno putem [kagglehub](#) biblioteke, koja dataset automatski smješta u

`/root/.cache/kagglehub/datasets/kipshidze/drunken-vs-sober-infrared-image-dataset/versions/5/drunken_sober_data`

#### 2. Struktura i broj instanci

**Struktura:**

`drunken_sober_data/`

├── 20mins/ → slike osoba 20 minuta nakon konzumacije

├── 40mins/ → slike osoba 40 minuta nakon konzumacije

├── 60mins/ → slike osoba 60 minuta nakon konzumacije

└── sober/ → slike osoba u trijeznom stanju

**Broj instanci:**

Broj instanci po klasama: {'60mins': 120, '20mins': 123, 'sober': 122, '40mins': 121}

=> ukupno: 486 instanci

#### 3. Atributi

Pošto se radi o dataset-u slika, nema eksplicitnih atributa kao u tabelarnim podacima. Atributi se mogu izvesti iz:

- Naziva fajla (`ime_broj_polozaj_pol_starost_temperatura.jpg`)
- Vizualnih karakteristika slike (preko ekstrakcije feature-a)

#### 4. Broj klasa

Klasifikacioni problem: 4 klase

- `sober`
- `20mins`
- `40mins`
- `60mins`

#### 5. Količina podataka

Ukupna veličina podataka: 1.34 MB

#### 6. Podjele: trening / validacija / test

Train set:

Drunk state	327
Sober state	110

Validation set:

Drunk state	18
Sober state	6

Test set:

Drunk state	19
Sober state	6

#### 7. Potencijalni rizici

- Imbalans klasa: broj slika blago varira među klasama.
- Vizuelna sličnost između klasa: slike `20min`, `40min`, `60min` mogu biti vrlo slične.

- Mala veličina dataseta: rizik od overfitting-a.
- Bias: slike su snimane pod istim uslovima i sa istim osobama, model može naučiti nebitne obrasce.

### 3.3 Pretprocesiranje podataka

Prije procesa treniranja podataka od ključne je važnosti pravilna priprema ulaznih podataka. Ova faza direktno utiče na tačnost i generalizaciju modela. U ovom projektu primijenjene su sljedeće metode pretprocesiranja:

1. Čitanje i konverzija infracrvenih slika
  - One se učitavaju pomoću `cv2.imread(path, cv2.IMREAD_UNCHANGED)`, čime se zadržava originalna dubina slike.
  - Slike se konvertuju iz BGR formata (default OpenCV format) u RGB, kako bi bile kompatibilne s `TensorFlow/Keras` standardima.
2. Mapiranje infracrvenih slika u Jet Colormap
  - Infracrvene slike nemaju boje — vizualno su teže razumljive.
  - Koristi se `cv2.applyColorMap(..., cv2.COLORMAP_JET)` da se slike mapiraju na Jet kolornu skalu radi boljeg uvida u varijacije temperature/podataka.
  - Na ovaj način, slike se transformišu u pseudo-RGB, što omogućava bolju reprezentaciju ulaza za CNN.
3. Resize i interpolacija
 

Slike se skaliraju na uniformnu veličinu 256x256 piksela pomoću `tf.keras.preprocessing.image.smart_resize(...)` uz bicubičnu interpolaciju.

Ova uniformnost dimenzija je neophodna jer CNN model očekuje fiksnu veličinu ulaza.
4. Normalizacija piksela

Nakon mapiranja i interpolacije, pikseli ne moraju biti u standardnom rasponu `[0, 1]`.

Slike se normalizuju:

```
img -= img.min()  
img /= (img.max() - img.min())
```

čime se svi pikseli skaliraju u opseg `0–1`, što ubrzava i stabilizuje proces treniranja.

## 4. Odabir, formiranje, treniranje i testiranje modela

U ovom projektu cilj je bio razviti pouzdan model koji može automatski klasifikovati vozača kao "Sober" ili "Drunk" na osnovu infracrvenih slika lica. Problem se formalno posmatra kao binarni problem klasifikacije slika, gdje su metode dubokog učenja idealan pristup zbog sposobnosti da uče složene obrasce iz podataka.

### 4.1 Izabrana metoda

Za rješavanje ovog problema odabrana je metoda konvolucione neuronske mreže (CNN) iz domena dubokog učenja, jer su CNN modeli su posebno efikasni kod analize slike i prepoznavanja obrazaca (npr. temperaturnih razlika kod infracrvenih snimaka lica). Model je definisan kao sekvenca `Conv2D → MaxPooling → Dense slojeva`, sa sigmoid aktivacijom na izlazu, što je standardno za binarnu klasifikaciju.

### 4.2 Korištene tehnologije

#### 1. Python

Glavni programski jezik projekta zbog svoje bogate podrške za obradu slike i modeliranje neuronskih mreža.

#### 2. TensorFlow / Keras

- Korišten za definiciju, treniranje i evaluaciju CNN modela.

- Omogućava brzo definisanje modela koristeći Sequential i Functional API.
- Podržava GPU akceleraciju za brže treniranje.

### 3. OpenCV

Koristi se za:

- Konverziju slika u RGB i njihovo skaliranje.
- Mapiranje piksela u Jet colormap, radi bolje vizualne interpretacije i obrade.

### 4. NumPy

Za efikasno upravljanje matricama slika i labelama, kao i za konverziju u np.array formate koje model očekuje.

### 5. Sklearn

Korišten za:

- Evaluaciju rezultata modela (classification\_report, accuracy\_score, confusion\_matrix).
- 
- Automatsko izračunavanje class weights za balansiranje klasa prilikom treniranja (mada se u ovom projektu to nije implementiralo, ali je pripremljeno).

### 7. Matplotlib / Seaborn

Za vizualizaciju rezultata: konfuzione matrice i analize performansi modela.

## 4.3 Treniranje modela

Model je treniran na setu infracrvenih slika lica koje su klasifikovane kao “Sober state” i “Drunk state”. Slike su prethodno pretprocesirane – konvertovane iz .tif formata u RGB, skalirane na oblik (256, 256, 3) i normalizovane u opseg [0,1].

Model je definisan korištenjem konvolucionih slojeva (CNN), sa pet slojeva Conv2D + MaxPooling, zatim Flatten i potpuno povezani (Dense) slojevi, završavajući sa sigmoid aktivacijom jer se radi o binarnoj klasifikaciji.

Model je treniran pomoću:

- Adam optimizatora, poznatog po stabilnosti i brzom konvergiranju.

- Binary Crossentropy funkcije gubitka (loss function) koja je standardna za binarne klasifikacione zadatke.
- 30 epoha, što je omogućilo modelu dovoljno vremena da nauči bez prekomjernog overfittinga.
- Trening je pokrenut nad x\_train i y\_train, dok su x\_valid i y\_valid korišteni za validaciju modela kroz epohe.

## 4.4 Korištene metrike evaluacije

Model je testiran pomoću različitih metrika kako bi se što preciznije procijenila njegova tačnost i sposobnost razlikovanja klasa "Sober state" i "Drunk state". Korištene metrike uključuju:

- Preciznost (Precision) – mjeri tačnost pozitivnih predikcija, tj. koliko predikcija koje su označene kao "drunk" zaista jesu pijane osobe.
- Odziv (Recall) – pokazuje koliko je stvarno pijane osobe model uspio prepoznati od ukupnog broja stvarno pijanih osoba.
- F1-score – harmonijska sredina između preciznosti i odziva, posebno korisna kod neuravnoteženih skupova podataka.
- Accuracy (Tačnost) – ukupni procenat tačno klasificiranih slika.
- Confusion Matrix – tabela koja prikazuje broj ispravno i pogrešno klasifikovanih primjera za svaku klasu.

## 4.5 Diskusija rezultata

Na testnom skupu dobijeni su sljedeći rezultati:

- **Accuracy (tačnost):** 72%
- **Precision:**

- Klasa 0 ("Sober state"): 0.33
- Klasa 1 ("Drunk state"): 0.77
- **Recall:**
  - Klasa 0: 0.17
  - Klasa 1: 0.89
- **F1-score:**
  - Klasa 0: 0.22
  - Klasa 1: 0.83

Confusion matrix je pokazao sljedeće:

	<b>Predicted Sober</b>	<b>Predicted Drunk</b>
Actual Sober	1 (True Neg.)	5 (False Pos.)
Actual Drunk	2 (False Neg.)	17 (True Pos.)

Na osnovu prikazanih metrika, može se zaključiti da model ima dobru sposobnost detekcije pijanih osoba, što pokazuje visok recall (0.89) i f1-score (0.83) za klasu "Drunk state". S druge strane, model je manje uspješan u detekciji trijeznih osoba, što potvrđuje nizak recall (0.17) i f1-score (0.22) za "Sober state".

Ovo ukazuje na nebalansiranost skupa podataka, gdje je broj pijanih slika znatno veći od broja trijeznih, što uzrokuje da model ima tendenciju da više "nagađa" da je osoba pijana što je bio jedan od rizika prije treniranja modela. Iako je opšta tačnost modela



zadovoljavajuća, za realnu upotrebu (npr. u sistemima nadzora vozača) bilo bi važno dodatno poboljšati tačnost detekcije "Sober state" kako bi se izbjegle lažne uzbune.

## 5. Osvrt na problem i dobijeno rješenje

Sva potrebna implementacija modela (pretpocesiranje, model i testiranje) se može naći na sljedećem linku: [🔗 DrunkenDriverDetection.ipynb](#)

### 5.1 Postignuti rezultati

Postignuti rezultati pokazuju da model ima zadovoljavajuću tačnost u detekciji pijanog stanja, pri čemu je postignuta ukupna tačnost klasifikacije od 72%. Posebno se ističe visoka vrijednost *recall-a* (89%) i *F1-score-a* (83%) za klasu „Drunk state“, što ukazuje na to da je model u velikoj mjeri uspješno naučio prepoznavati karakteristike opijenosti na termalnim slikama.

Ipak, performanse modela za klasu „Sober state“ su značajno lošije, sa recall-om od svega 17% i F1-score-om od 22%. Ovo ukazuje na neravnotežu u prepoznavanju klasa, što može biti posljedica neravnomjerne distribucije slika u datasetu, gdje su stanja opijenosti (20, 40 i 60 minuta) daleko brojnije zastupljena od trezvenog stanja.

### 5.2 Šta se moglo bolje uraditi

#### 1. Balansiranje klasa

- Tokom treniranja nije korištena opcija `class_weights`, koja bi pomogla modelu da „nauči“ da ne zanemaruje manje zastupljene klase. Uključivanjem težina klasa moglo se postići bolje prepoznavanje „Sober“ primjera.

#### 2. Veći i raznovrsniji skup podataka

- Dataset ima ograničen broj uzoraka za klasu „Sober“, što otežava modelu da generalizuje. Prikupljanjem dodatnih slika trijeznih ljudi ili augmentacijom postojećih podataka moglo bi se poboljšati prepoznavanje.

#### 3. Naprednija arhitektura modela

- Iako je korišten jednostavan CNN model, mogla se primijeniti neka od pretrenirana mreža (npr. MobileNet, EfficientNet) za bolje performanse. Ove mreže bolje generalizuju i često daju preciznije rezultate i na manjim skupovima podataka.